



Projet Chatbot Poulpes

Knowledge Graph Pipeline

Construction · Alignement · Raisonnement & KGE · RAG

Bilal Gougis & Chadi Al Kerdi
Cours : Web Mining & Sémantique

Mars 2026

1. Acquisition de Données & Extraction d'Information	3
1.1 Domaine & Sources.....	3
1.2 Architecture du Crawler	3
1.3 Extraction NLP	3
1.4 Cas d'Ambiguïté	3
2. Construction & Expansion de la Base de Connaissances	4
2.1 Modélisation RDF	4
2.2 Entity Linking	4
2.3 Alignement des Prédicats	4
2.4 Stratégie d'Expansion.....	4
2.5 Statistiques Finales	4
3. Raisonnement SWRL	5
4. Knowledge Graph Embeddings.....	6
4.1 Préparation des Données	6
4.2 Modèles & Hyperparams	6
4.3 Résultats	6
4.4 Analyse Head vs Tail.....	6
4.5 Analyse de Sensibilité	6
4.6 Voisins Proches & PCA	6
5. RAG sur RDF/SPARQL	7
5.1 Résumé de Schéma	7
5.2 Génération SPARQL	7
5.3 Self-Repair	7
5.4 Évaluation (8 questions)	7
5.5 Interface	7
6. Réflexion Critique.....	8
6.1 Impact de la Qualité de la KB	8
6.2 Problème des Relations Littérales	8
6.3 Rule-based vs Embedding-based.....	8
6.4 Améliorations Possibles	8

1. Acquisition de Données & Extraction d'Information

1.1 Domaine & Sources

Le domaine choisi est la biologie des céphalopodes, plus spécifiquement les poulpes (Octopoda). Ce choix se justifie par la richesse taxonomique de ce groupe (plus de 300 espèces décrites) et la disponibilité de sources en français et en anglais.

Nous avons ciblé 38 pages web provenant de 4 sources principales :

Source	Pages	Mots	Type
Wikipedia FR	16	20 402	Encyclopédie (API)
MarineSpecies.org	5	5 579	Base taxonomique
URLs spécialisées	16	27 083	Reporterre, Larousse, DORIS, etc.
GuideDesEspèces.org	1	1 452	Guide de pêche durable
Total	38	55 516	

1.2 Architecture du Crawler

Le crawler utilise deux stratégies d'acquisition : l'API Wikipedia (extracts en texte brut) pour les 16 articles encyclopédiques, et le scraping HTML avec BeautifulSoup pour les autres sources. Chaque page est vérifiée contre le fichier robots.txt du site avant le téléchargement. Un délai d'1 seconde entre chaque requête (CRAWL_DELAY=1.0) assure le respect des serveurs.

Les pages contenant moins de 150 mots sont rejetées (MIN_WORD_COUNT). Le contenu est nettoyé (suppression des balises nav, footer, script, style) et dédoublé par hash MD5. Le résultat est stocké en format JSONL (crawler_output.jsonl).

1.3 Extraction NLP

L'extraction utilise spaCy avec le modèle fr_core_news_md. Deux types d'information sont extraits :

NER (Named Entity Recognition) : extraction des entités nommées (PER, ORG, LOC, MISC). 2 646 entités uniques identifiées dont 1 043 MISC, 716 PER, 612 LOC, 258 ORG, et 17 SPECIES (ajoutées via un dictionnaire spécifique au domaine).

Relations : extraction des triplets sujet-verbe-objet par analyse des dépendances syntaxiques. 503 relations uniques extraites. Les verbes les plus fréquents sont : posséder (16), faire (13), utiliser (12), contenir (11).

1.4 Cas d'Ambiguïté

1. Octopus vulgaris : spaCy le classe parfois comme PER (personne) car le format binominal ressemble à un nom propre. Notre dictionnaire ESPECES corrige ce problème.

2. Manche : classifié LOC par spaCy, ce qui est correct pour le département français, mais le terme désigne également la Manche (mer) dans le contexte maritime. L'entity linking avec Wikidata résout cette ambiguïté.

3. Chromatophore : classifié MISC par spaCy alors qu'il s'agit d'un organe biologique spécifique. La catégorie MISC de spaCy est un fourre-tout qui mérite un post-traitement.

2. Construction & Expansion de la Base de Connaissances

2.1 Modélisation RDF

L'ontologie privée définit 9 classes (Species, Researcher, Institution, Location, Behavior, BodyPart, Habitat, Predator, Prey) et 4 propriétés d'objet (habitatOf, preyOf, studiedBy, locatedIn). Les namespaces sont : oct: pour l'ontologie et ent: pour les entités.

La KB initiale contient environ 8 800 triplets, issus des entités NER et des relations extraites par spaCy. Les relations privées sont de type entité → littéral texte (ex: ent:pieuvre oct:masquer "sa fuite"), ce qui constitue une limitation pour le KGE (voir Section 6).

2.2 Entity Linking

L'alignement avec Wikidata utilise l'API wbsearchentities. 397 entités sur 500 candidates ont été liées (79%), avec une confiance moyenne de 0.948.

Exemples : ent:Octopus_vulgaris → wd:Q190782 (confiance 0.85), ent:mer_Méditerranée → wd:Q4918 (confiance 1.0). Les entités non liées sont généralement des expressions complexes ("Oscar 2021 du meilleur film documentaire") ou des concepts trop spécifiques.

2.3 Alignement des Prédicats

5 prédicats privés sur 30 ont été alignés manuellement avec Wikidata : posséder → P527 (has part), utiliser → P366 (use), trouver → P131 (located in), consommer → P1034 (main food source), produire → P1056 (product produced). Les 25 restants (faire, voir, agrandir, etc.) n'ont pas d'équivalent direct dans le vocabulaire Wikidata.

2.4 Stratégie d'Expansion

L'expansion repose sur des entités ancrs biologiques vérifiées : Q40152 (Octopoda), Q26899 (Cephalopoda), Q131257 (Octopus), Q190782 (Octopus vulgaris), Q1266322 (Enteroctopus dofleini), Q1476486 (Hapalochlaena), etc.

Point critique : une première version utilisait des QIDs incorrects (Q1077 = un film, Q192882 = gouvernorat d'Irak), ce qui avait injecté du bruit géopolitique massif. Après correction, l'expansion 2-hop est ciblée sur les taxons (entités ayant P171 ou P105) et un nettoyage post-expansion supprime les prédicats hors-domaine.

2.5 Statistiques Finales

Métrique	Valeur
Triplets totaux	~20 600
Entités privées (ent:)	~8 600
Triplets Wikidata	~11 800
P171 (parent taxon)	101
P105 (taxon rank)	81
P1672 (preys on)	19
P150/P530/P2936 (bruit)	0 (nettoyé)

3. Raisonnement SWRL

Nous avons implémenté une règle SWRL avec OWLReady2 pour démontrer le raisonnement déductif sur notre ontologie :

Règle : $\text{Species}(?s) \wedge \text{venom_level}(?s, ?v) \wedge \text{greaterThan}(?v, 0) \rightarrow \text{DangerousSpecies}(?s)$

Cette règle classe automatiquement les espèces venimeuses comme dangereuses. Appliquée à *Hapalochlaena* (venom_level=5) et *Octopus vulgaris* (venom_level=0), le résultat attendu est que seul *Hapalochlaena* soit classifié *DangerousSpecies*.

Note : le raisonneur Pellet nécessite Java 21+. Notre environnement disposait de Java 8, ce qui a empêché l'exécution effective du raisonnement. Les résultats attendus sont documentés.

4. Knowledge Graph Embeddings

4.1 Préparation des Données

La KB est nettoyée en supprimant les littéraux, les métadonnées (rdf:type, rdfs:label, owl:sameAs, prov:wasDerivedFrom), les URLs de fichiers, et les identifiants externes Wikidata (P18, P214, P646, etc.). Les relations avec moins de 3 occurrences sont également filtrées.

Le split est 80/10/10 : ~8 200 triplets d'entraînement, ~1 000 de validation, ~1 000 de test.

4.2 Modèles & Hyperparams

Trois modèles sont entraînés avec des hyperparams identiques pour une comparaison équitable : embedding_dim=200, Adam optimizer (lr=5e-4), bernoulli negative sampling (10 négatifs/positif), early stopping sur Hits@10 (patience=10).

TransE : MarginRankingLoss (margin=2.0). Modèle translationnel : $h + r \approx t$.

DistMult : MarginRankingLoss (margin=2.0). Modèle bilinéaire : $\text{score} = h^T \text{diag}(r) t$.

ComplEx : SoftplusLoss avec régularisation L2 (1e-5). Embeddings complexes pour les relations asymétriques.

4.3 Résultats

Modèle	MRR	Hits@1	Hits@3	Hits@10
TransE	0.19	0.07	0.25	0.40
DistMult	0.34	0.24	0.38	0.52
ComplEx	0.00	0.00	0.00	0.00

DistMult est clairement le meilleur modèle (MRR=0.34, Hits@10=0.52). TransE montre des performances honorables. ComplEx n'a pas convergé sur cette KB de taille réduite (~10k triplets), probablement en raison du manque de données pour les embeddings complexes.

4.4 Analyse Head vs Tail

DistMult prédit mieux les tails (MRR tail=0.33 vs head=0.29), cohérent avec la structure taxonomique : prédire «Octopus → P171 → ?» (tail) est plus facile car il y a moins de parents que d'enfants.

4.5 Analyse de Sensibilité

L'analyse 20k/50k/Full donne des résultats identiques car la KB ne contient que ~10k triplets, en dessous du premier seuil de sous-échantillonnage. Cela confirme l'observation de l'énoncé : une KB < 10k triplets ne permet pas d'observer de différence de sensibilité à la taille.

4.6 Voisins Proches & PCA

La visualisation PCA montre principalement des entités de type Location (océans, mers). Les entités Species et Taxon sont sous-représentées dans les données d'entraînement car les relations privées (oct:chasser, oct:vivre) sont de type entité → littéral, incompatibles avec le KGE.

5. RAG sur RDF/SPARQL

5.1 Résumé de Schéma

Le résumé injecté dans les prompts LLM contient : les préfixes RDF, les classes et prédicats disponibles (avec fréquence), les labels des entités clés, et des exemples de triplets pertinents. La taille est adaptée au modèle (5000 caractères pour Llama 3.2 1B).

5.2 Génération SPARQL

Le pipeline utilise une approche hybride :

Templates SPARQL : pour les patterns de questions courants (habitat, taxonomie, espèces, propriétés). Un détecteur de pattern analyse la question et sélectionne le template adéquat.

Génération LLM : pour les questions atypiques, Llama 3.2 1B génère le SPARQL à partir du schéma. La température est fixée à 0.1 pour un output déterministe.

5.3 Self-Repair

Si le SPARQL échoue, le LLM reçoit l'erreur et le schéma pour générer une requête corrigée. En dernier recours, un fallback intelligent cherche les propriétés de l'entité mentionnée dans la question.

5.4 Évaluation (8 questions)

Les réponses RAG sont comparées au baseline (LLM seul). Le baseline (Llama 3.2 1B sans KB) produit des réponses souvent génériques ou hallucinées, tandis que le RAG retourne des données ancrées dans le graphe. Une étape de synthèse en langage naturel reformule les résultats SPARQL bruts.

5.5 Interface

L'interface Gradio permet de poser des questions, choisir le modèle Ollama, afficher la requête SPARQL générée, et comparer baseline vs RAG côte à côte. Une démo CLI est également disponible.

6. Réflexion Critique

6.1 Impact de la Qualité de la KB

La principale leçon de ce projet est l'importance cruciale de la qualité des données. L'utilisation de QIDs Wikidata incorrects (Q1077 = un film au lieu du genre Octopus) a initialement produit une KB remplie de bruit géopolitique, avec un MRR de 0.12. Après correction des QIDs et nettoyage, le MRR a doublé (DistMult: 0.34).

6.2 Problème des Relations Littérales

Les relations extraites par spaCy sont de type entité → littéral texte (ex: pieuvre → oct:masquer → "sa fuite"). Or le KGE ne fonctionne qu'avec des triplets entité → entité. Cela signifie que les 498 relations privées ne contribuent pas aux embeddings. C'est une limitation structurelle du pipeline NLP → KGE.

6.3 Rule-based vs Embedding-based

Le raisonnement SWRL est explicite, interprétable et garanti correct (Species + venimeux → DangerousSpecies). Les embeddings KGE sont implicites, apprennent automatiquement des patterns, mais sont difficiles à interpréter et échouent sur les petites KB. Les deux approches sont complémentaires : SWRL pour les inférences précises, KGE pour la découverte de liens latents.

6.4 Améliorations Possibles

- 1. Relations entité→entité** : remplacer les littéraux par des entités (ex: oct:masquer "sa fuite" → oct:uses ent:ink_cloud). Cela nécessiterait un post-traitement NLP plus poussé.
- 2. Plus de sources biologiques** : intégrer DBpedia, NCBI Taxonomy, ou GBIF pour enrichir les données taxonomiques.
- 3. Modèle LLM plus grand** : Llama 3.2 1B en CPU est lent (~30s/réponse). Un modèle 3B optimisé ou un accès GPU améliorerait l'expérience utilisateur.
- 4. Évaluation automatique** : implémenter des métriques automatiques (F1 sur les entités retournées) au lieu de l'évaluation manuelle.